UNIVERSIDADE FEDERAL DE MINAS GERAIS

Escola de Engenharia

Engenharia Elétrica

COMPUTAÇÃO EVOLUCIONÁRIA

Relatório 2 – Problema da Mochila

Gabriel Saraiva Espeschit - 2015065541

19 de outubro de 2019

1. Introdução

O objetivo do trabalho é escrever um algoritmo genético capaz de resolver o problema da mochila. O trabalho foi desenvolvido em Python. O problema da mochila foi expresso da seguinte maneira:

"*Dados N itens, onde cada item possui um benefício (v_j) e um peso associado (w_j), o problema consiste em selecionar o subconjunto de itens que maximiza a soma dos benefícios sem ultrapassar a capacidade (cap) da Mochila*."

2. Metodologia

O primeiro passo para resolver o problema proposto foi definir como representar as diferentes possibilidades de conteúdo que estaria dentro da mochila. Dada uma matriz, representado na figura abaixo, que define os valores e pesos dos objetos mochila, usou-se da representação binária para essa função.

	Obj_1	Obj_2	Obj_3	Obj_4	Obj_5	Obj_6	Obj_7	Obj_8
Peso	10	18	12	14	13	11	8	6
Valor	5	8	7	6	9	5	4	3

Figura 1 - Pesos e valores de cada objeto do problema

Como exemplo, tomamos o vetor para representação binária abaixo:

$$[0, 0, 0, 0, 1, 0, 1, 1]$$

O valor dos objetos seria de 16 (9 + 4 + 3) e o seu peso de 27 (13 + 8 + 6).

A partir disso, criou-se uma classe para representar os valores dos objetos, os pesos dos objetos, o número de objetos e a capacidade máxima suportada pela mochila. O algoritmo tem seu funcionamento conforme as seguintes etapas:

1) Inicialização: se cria uma matriz com representações binárias randômicas de dimensão N x *num_p*, em que N é o número de objetos a serem selecionados (no caso do problema é 8) e *num_p* é um número de indivíduos que pode ser definido na chamada da função (o arbitrário é de 10).
2) Avaliação do fitness: o fitness da população é avaliado com base em uma função que foi repassada para o aluno. Essa função valoriza os membros com valores mais altos, penalizando-os caso excedam o limite de carga da mochila.
3) Iteração: no processo de iteração se faz algumas ações valem destaque:
    a. Seleciona-se 2 pais com base em seus fitness utilizando o método da roleta. Em seguida, cria-se uma população de *num_p* filhos. O cruzamento pode ser realizado com base em uma probabilidade *prob_def* (o número padrão é de 0.8) dos 2 pais selecionados, e é um crossover simples. Caso não haja cruzamento, os filhos são cópias dos pais.
    b. Os filhos sofrem mutações com base em uma probabilidade *prob_mut* (o padrão é de 0.02)

c. Os filhos gerados na matriz são comparados com os indivíduos da população atual. Caso o fitness do enésimo filho seja melhor que o fitness do enésimo individuo atual, o filho toma seu lugar. Esse método de seleção pode ser considerado extremamente elitista, mas provou-se muito bom para garantir a rápida convergência do algoritmo, como vamos verificar abaixo.
d. Por fim é feita uma avaliação da nova população que irá compor os pais da próxima geração. O fitness do melhor membro e o fitness médio é preservado.

4) É plotado um gráfico contendo o fitness médio e o melhor fitness de cada geração, o melhor individuo encontrado, após rodar o algoritmo diversas vezes, foi o:

[1 0 1 0 1 0 0 0]

Com um valor de 21 e um peso de 35.

3. Resultados

Experimentou-se com diferentes valores de *prob_def* (probabilidade de ocorrer um cruzamento) e *prob_mut* (probabilidade de ocorrer uma mutação). Os resultados seguem abaixo:

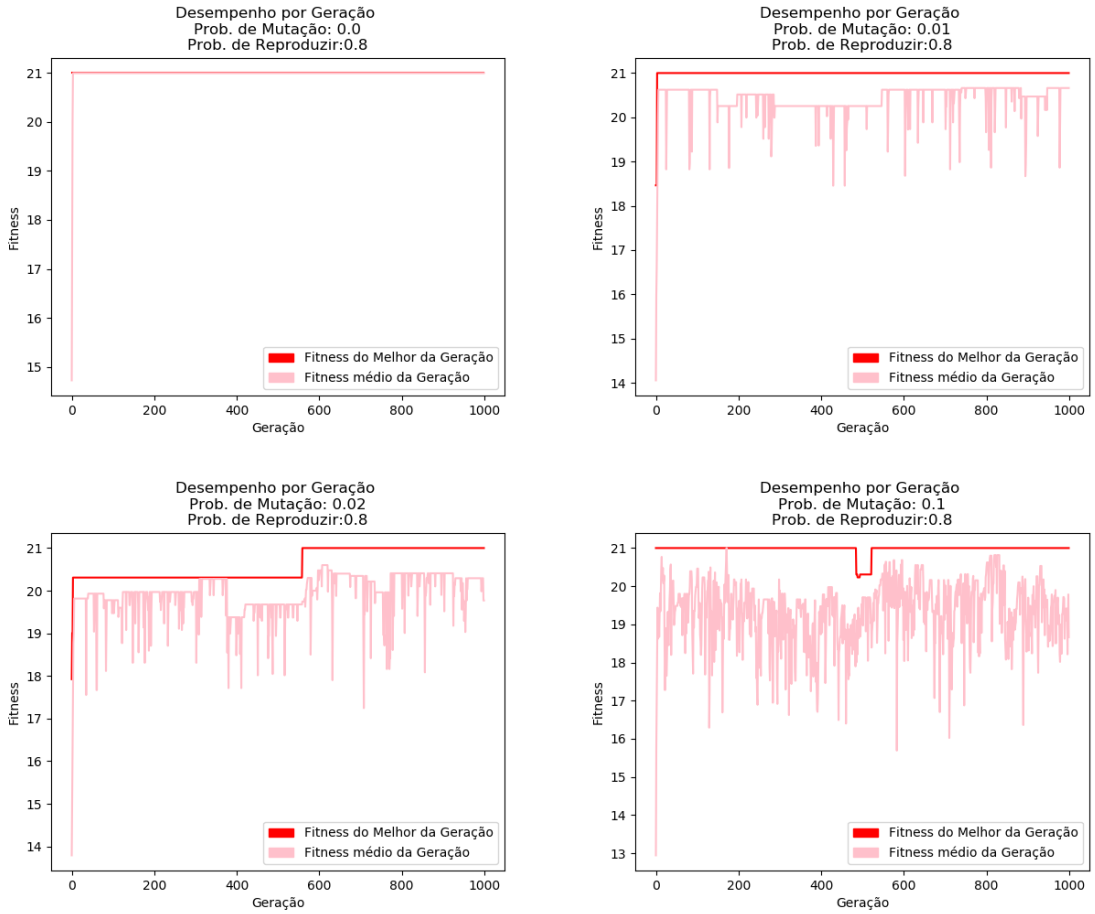

3. Resultados

Experimentou-se com diferentes valores de *prob_def* (probabilidade de ocorrer um cruzamento) e *prob_mut* (probabilidade de ocorrer uma mutação). Os resultados seguem abaixo:

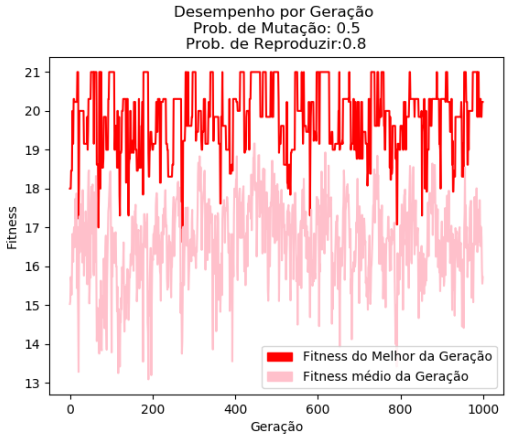

Figura 2 - Manteve-se a probabilidade de reprodução constante em 0.8 e alterou-se a probabilidade de mutação. Podemos ver que em: a) prob_mut = 0. Atinge o resultado ótimo e tanto a média quanto o melhor individuo ficam constantes, não há oscilações; b) prob_mut = 0.01. As oscilações como um todo são controladas e a média tende á solução ótima; c) prob_mut =0.02. As mutações fazem com que a média oscile mais, no entanto, esse gráfico exemplifica a importância de usar mutações em um algoritmo evolucionário, pois, caso não houvesse mutações, é muito provável que cairíamos em um máximo local e não chegaríamos ao resultado ideal, como pode ser visto pela longa reta no melhor indivíduo que durou até a geração 600, aproximadamente; d) prob_mut = 0.1. As oscilações na média estão mais descontroladas e chegam a piorar o melhor candidato da posição ideal, brevemente; e) prob_mut = 0.5. As mutações causam com que o algoritmo entre um estado estocástico, oscilações são vistas tanto na média quanto na curva de melhor individuo e o algoritmo, nessa situação, não converge.

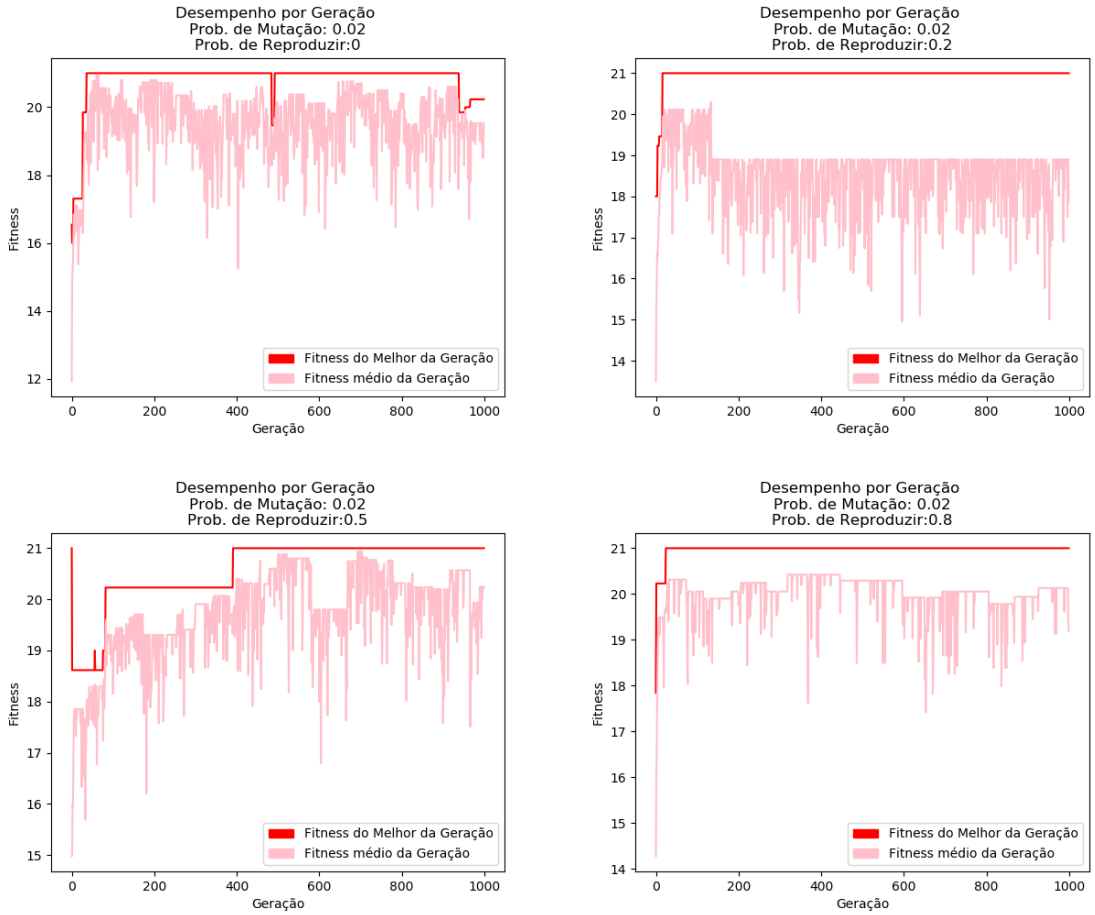

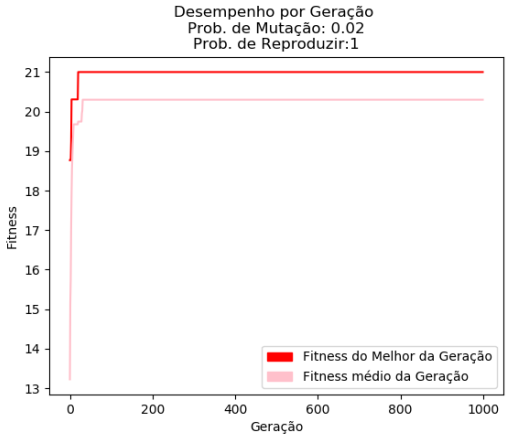

Figura 3 - Manteve-se a probabilidade de mutação constante em 0.02 e alterou-se a probabilidade de reprodução. Podemos ver que em: a) prob_def = 0. Apesar de não ocorrer reprodução e todo filho ser uma cópia do pai, as mutações causam com que cheguemos à solução ideal. No entanto, como o processo é estocástico e não há uma forma de preservar essa melhor solução ao longo das gerações de forma efetiva, o melhor individuo logo é deposto por um que tem um fitness pior que o dele; b,c e d) prob_def = 0.2, 0.5 e 0.8. Nessas situações o algoritmo apresentou um comportamento semelhante, a média chegava em um pico, antes de alguns indivíduos sofrerem mutações que o tornassem menos aptos abaixando o valor. Esses indivíduos eram rapidamente repostos por indivíduos melhores que fazia com que a média voltasse ao seu pico anterior. Nesses casos, os algoritmos sempre convergiam; e) podemos reparar uma situação peculiar aqui: a média para de oscilar. Para o leitor atento, isso é um resultado de nossa função de substituição de filhos. Uma vez que toda a população está infestada de indivíduos cujos filhos são tão aptos quantos os pais, os pais não serão substituídos, e nossa média ficará constante.

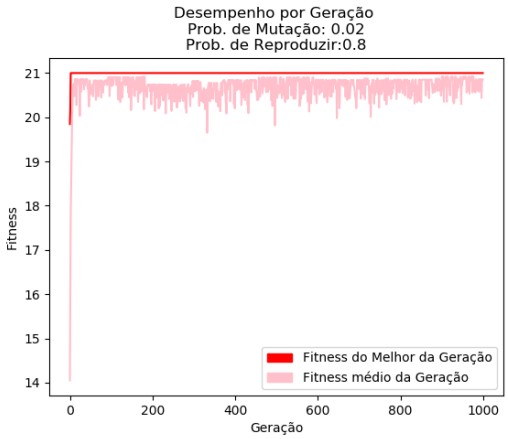

Figura 4 - Aqui usamos os valores padrões para probabilidade de mutação e reprodução, porém aumentamos o tamanho da população de 10 para 50 indivíduos. Podemos ver que a média fica muito mais compacta e próxima ao indivíduo ótimo, o que mostra que nosso algoritmo converge corretamente, conforme esperado

4. Código

O código desenvolvido em Python pode ser visto abaixo:

```python
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches

# Classe Mochila para definir os parâmetros de inicialização e ficar fácil de mudar posteriormente
class Mochila:
    N = 8  # Número de Objetos
    cap = 35  # Capacidade
    wj = [10, 18, 12, 14, 13, 11, 8, 6]  # Peso
    vj = [5, 8, 7, 6, 9, 5, 4, 3]  # Valor

# Função para calcular o fitness de cada linha da matriz população
def fitness(solution, values, weights, cap):
    rho = max(np.divide(values, weights))
    total_benefit = np.dot(solution, values)
    total_weight = np.dot(solution, weights)
    if total_weight > cap:
        f = total_benefit - rho * (total_weight - cap)
    else:
        f = total_benefit
    return f

# Função para selecionar os pais usando o método da roleta
def sel_pais(prob, num_pais=2):
    current = 1
    a = []
    parent_index = []

    for i in range(len(prob)):
        if i == 0:
            a.append(prob[i])
        else:
            a.append(prob[i]+a[i-1])

    while current <= num_pais:
        r = np.random.rand(1)
        i = 0
        while a[i] < r:
            i += 1
        parent_index.append(i)
        current += 1
    return parent_index

# Função para fazer um cruzamento simples entre 2 indivíduos da população
def cruzamento(p1, p2):
    n = len(p1)
    pos = np.random.randint(1, n)
    f1 = np.concatenate([p1[0:pos], p2[pos:]])
    f2 = np.concatenate([p2[0:pos], p1[pos:]])

    return f1, f2

# Função principal de execução do programa
def mochila(it=1000, num_p=10, prob_def=0.8, prob_mut=0.02):
    # Inicialização do algoritmo
    iteracao = 0
    melhor = []
    media = []
```

```
    m1 = Mochila
    # Inicializando a população
    solution = np.random.randint(2, size=(num_p, m1.N))
    # Processo de iteração
    while iteracao < it:
        # Calculando o fitness
        fit = []
        for i in range(num_p):
            fit.append(fitness(solution[i], m1.vj, m1.wj, m1.cap))
        fit_prob = [(fit[i]/sum(fit)) for i in range(len(fit))]
        filhos = np.zeros((num_p, m1.N))
        aux_cruz = 0
        while aux_cruz < num_p-1:
            # Selecionando dois pais usando o metodo da roleta
            pais = sel_pais(fit_prob)
            # Fazendo o cruzamento
            prob_cross = np.random.rand(1)
            if prob_cross < prob_def:
                f1, f2 = cruzamento(solution[pais[0]], solution[pais[1]])
            else:
                f1, f2 = solution[pais[0]], solution[pais[1]]
            # Fazendo mutações aos filhos
            for i in range(m1.N):
                prob_m = np.random.rand(1)
                if prob_m < prob_mut:
                    f1[i] = int(not(f1[i]))
                    f2[i] = int(not(f2[i]))
            filhos[aux_cruz] = f1
            filhos[aux_cruz+1] = f2
            aux_cruz += 2
        # Acrescentando os filhos a população
        # Caso o fitness do ìesimo filho for maior que o do ìesimo membro, substitua-o
        for n in range(num_p-1):
            if fitness(filhos[n], m1.vj, m1.wj, m1.cap) > fit[n]:
                solution[n] = filhos[n]

        # Avaliando a população
        melhor.append(sorted(fit)[-1])
        media.append(sum(fit)/len(fit))
        print(f'Melhor: {sorted(fit)[-1]}\n Média:{sum(fit)/len(fit)} Geração: {iteracao}')
        iteracao += 1
    print(solution[fit.index(sorted(fit)[-1])])
    plt.plot(melhor, c='r')
    plt.plot(media, c='pink')
    green_patch = mpatches.Patch(color='r', label='Fitness do Melhor da Geração')
    blue_patch = mpatches.Patch(color='pink', label='Fitness médio da Geração')
    plt.legend(handles=[green_patch, blue_patch])
    # plt.plot(pior, c='r')
    plt.title(f'Desempenho por Geração \nProb. de Mutação: {prob_mut}\nProb. de
Reproduzir:{prob_def}')
    plt.xlabel('Geração')
    plt.ylabel('Fitness')
    plt.show()

if __name__ == '__main__':
    mochila(it=1000, num_p=10, prob_def=0.8, prob_mut=0)
```